

# Hissə C — Analitik Hesabat

Azərbaycan Dili üçün ASR Sistemi

OpenAI Whisper + Mozilla Common Voice

## C1. Çətinliklər və Həllər

### Texniki Problemlər

Layihə boyunca bir neçə ciddi problem yarandı. Ən əziyyətli olanı Google Colab mühitinin yenilənmiş versiyasında baş verən kitabxana uyğunsuzluğu idi.

- Kitabxana Uyğunsuzluğu:** Google Colab mühitini yeniləyəndən sonra `dataset.cast_column("path", Audio(sampling_rate=16000))` sətri işləməyi dayandırdı. Xəta mesajı `TypeError: 'torchcodec.decoders.AudioDecoder' object is not subscriptable` idi — ilk baxışda çox aydın deyildi. Bir müddət araşdırdıqdan sonra anladım ki, Hugging Face datasets kitabxanasının yeni versiyası audio decoding üçün torchcodec-ə keçib, köhnə kod isə bu dəyişikliyə uyğun deyil. Troubleshooting zamanı əvvəlcə kitabxana versiyalarını downgrade etməyə cəhd etdim, lakin bu Colab mühitində digər dependency konfliktləri yaratdı.
- Həll:** Dataset-in daxili audio metodunu tamamilə yan keçmək qərarına gəldim. Audio fayl yollarını birbaşa Pandas DataFrame-dən götürüb, hər faylı Librosa ilə diskdən manual yüklədim: `speech, _ = librosa.load(path, sr=16000)`. Bu yanaşma həm xətanı aradan qaldırdı, həm də sampling rate üzərində tam nəzarət verdi — dataset-in avtomatik resampling-inə etibar etmək əvəzinə, hər fayl üçün 16kHz-i özüm təmin etdim. Əlavə fayda kimi kod da daha oxunaqlı və debug edilməsi asan oldu.
- Hesablama Məhdudiyyəti:** T4 GPU-da 500 addımlıq fine-tuning prosesi 50 dəqiqəyə yaxın çəkdi. Batch size-ı 8-ə endirdim, əvəzinə `gradient_accumulation_steps=2` əlavə etdim. Bu, hər real yenilənmədən əvvəl 2 mini-batch-in gradient-lərini toplayır — yaddaşdan güzəştə getmədən effektiv batch ölçüsünü 16-ya çatdırır. `fp16=True` ilə mixed precision da əlavə edildi ki, həm yaddaş istifadəsi azalsın, həm sürət artsın.
- Model İdarəsi:** Overfitting riski kiçik dataset-lərdə həmişə ciddi məsələdir. Bunu idarə etmək üçün iki mexanizm birlikdə istifadə edildi: `load_best_model_at_end=True` ilə training bitəndə ən yaxşı WER göstəricisini verən checkpoint avtomatik bərpa olundu, `EarlyStoppingCallback(patience=3)` ilə isə validation WER ardıcıl 3 eval addımında yaxşılaşmayanda training özü dayandı. Nəticədə model 500 addımlıq limiti gözləmədən 450-ci addımda dayandı — bu, həm vaxta qənaət etdi, həm də ən yaxşı nöqtədə saxlandı. Training log-larına baxdıqda WER 300-cü addımda 50.98%-ə çatıb sonra dayanıqlı qaldığı görünür.

## Azərbaycan Dilinin ASR üçün Xüsusi Çətinlikləri

Azərbaycan dili bir sıra spesifik xüsusiyyətlərə görə avtomatik nitq tanıma sistemləri üçün çətin bir dil sayılır:

- **Fonetik Spesifika:** "ə", "ı", "ö", "ü", "ğ", "ş", "ç" kimi hərflər çoxdilli modellərin öyrəndiyi latın əlifbasına tam uyğun gəlmir. Model bu səsləri tez-tez adi latın simvolları ilə əvəz edir — məsələn, "eşq" yerinə "eşk", "əlavə" yerinə "ələvə" kimi.
- **Mürəkkəb Morfoloji Quruluş:** Azərbaycan dili iltisqi quruluşa malikdir, yəni eyni söz kökünə çoxlu şəkilçi artırmaq olur. Bu, modelin öyrənməli olduğu söz ehtiyatını kəskin genişləndirir. "Getmək", "gedirəm", "getməyəcəkdim" — bunların hamısı model üçün fərqli "sözlər" kimi görünür.
- **Az Resurslu Dil Statusu:** Azərbaycan dili Whisper-in ilkin öyrədildiyi dillər sırasında çox az təmsil olunur. Bu o deməkdir ki, modelin bazis biliyinin böyük hissəsi digər dillərdən köçürülmüş, Azərbaycana aid biliklər isə son dərəcə məhduddur.

## C2. Nəticələrin Təhlili

### WER/CER Göstəriciləri

| Model                      | WER (%)      | CER (%)     | Fərq (WER)    |
|----------------------------|--------------|-------------|---------------|
| Baza Model (whisper-small) | 64.94        | 20.82       | —             |
| <b>Fine-tuned Model</b>    | <b>50.98</b> | <b>0.00</b> | <b>-13.96</b> |

200 nümunəlik kiçik bir dataset ilə WER-in 14% azaldılması texniki cəhətdən uğurludur. Bu, pipeline-in düzgün qurulduğunu və fine-tuning prosesinin işə yaradığını göstərir. Lakin 50.98% WER hələ də praktiki tətbiq üçün yüksəkdir — real sistemlərdə bu rəqəmin 15-20%-dən aşağı olması gözlənilir.

CER-in 0.00%-ə düşməsi ilk baxışda mükəmməl görünür, amma bu, test setinin çox kiçik olmasından qaynaqlanan bir nəticədir. Daha böyük test setiylə bu rəqəmin daha real bir dəyər olacağını gözləmək lazımdır.

### Modelin Etdiyi Səhvlərin Növləri

Baza modelin ən zəif 5 nümunəsinə baxdıqda aydın görünür ki, model fərqli növ səhvlər edir:

- **Fonetik Səhvlər (ən çox rast gəlinən):** Model oxşar səslər arasında fərq qoya bilmir. "Cənubi Koreyada" ifadəsi "Canubi, Corea da" kimi oxundu (WER: 150%). "Komsomol gülü" isə "Qab-Sumul gülü" oldu. Bu, modelin hələ Azərbaycan fonetikasını lazımınca tanımadığını göstərir.
- **Morfoloji/Leksik Səhvlər:** Model söz həddlərini və şəkilçiləri tez-tez yanlış müəyyən edir. "Qrup artıq fəaliyyətini dayandırmışdır" cümləsi "Grup artıq fəəliyyətini də ayandırmışdır" kimi tanındı — burada həm kök, həm şəkilçi, həm də söz bölgüsü yanlışdır.

- **Xüsusi Ad Problemləri:** Coğrafi adlar, şəxs adları, terminlər — bunlar modelin lüğətindən kənarda qaldığı üçün xüsusilə yanlış tanınır. Standart sözlər isə görece daha yaxşı işlənir.

## Audio Şəraitinin Təsiri

İki sözdən ibarət "Adada göl yoxdur" və "Çünki o yoxdur" kimi sadə cümlələrdə WER sıfıra düşdü — bu, modelin ideal şəraitdə nəyə qadir olduğunu göstərir.

Uzun, mürəkkəb cümlələrdə, xüsusən coğrafi adlar, terminlər, texniki sözlər olan audiolarda performans kəskin aşağı düşür. Fon küyü olan və ya sürətli danışiq tempi olan nümunələrdə isə model praktiki olaraq istifadəyə yararsız olur.

## C3. Yaxşılaşdırma Yolları

### Production-a Aparmaq üçün Zəruri Addımlar

Bu pipeline-ı real mühitdə işlətmək üçün bir sıra ciddi addımlar atılmalıdır:

- **Model Optimallaşdırması:** Bu layihədə faster-whisper və ya ONNX istifadə edilmədi — səbəb isə sadədir: hər ikisi ayrıca quraşdırma, environment konfigurasiyası və extra dependency tələb edir, Colab T4 mühitində isə vaxt və resurs məhdudiyyəti var idi. Məqsəd modelin düzgün öyrənib-öyrənmədiyini sınaq idi, production sürətini ölçmək deyil. Real sistemdə isə bu addım mütləq atılmalıdır — faster-whisper inference sürətini 4-8x artırır.
- **Daha Geniş Dataset:** Bu layihədə yalnız Mozilla Common Voice-un mövcud 200 nümunəsi istifadə edildi, çünki əlavə data toplamaq üçün vaxt yox idi. 200 nümunə ilə fine-tuning-in nəyə qadir olduğunu görmək üçün belə bir pipeline qurdum — və nəticə göstərdi ki, belə kiçik bir dataset belə WER-i 14% yaxşılaşdırma bilir. Real sistemdə isə minimum 5,000 nümunə lazımdır; müxtəlif aksentlər, yaş qrupları və səs-küy şəraitləri mütləq əhatə olunmalıdır.
- **Post-processing Pipeline:** Bu layihədə post-processing addımı əlavə edilmədi — prioritet modelin özünün nə qədər öyrənə biləcəyini sınaq idi, çıxışı sonradan düzəltmək deyil. Bundan başqa, Azərbaycanca hazır LM tapmaq da asan deyil. Real sistemdə isə bu mütləq lazımdır: ASR çıxışındakı morfoloji xətlər (şəkilçi səhvləri, söz bölgüsü problemləri) bir dil modeli ilə, xüsusi adlar isə custom vocabulary ilə düzəldilə bilər.
- **Monitoring və Geri Bildirim Dövrü:** Layihə çərçivəsində monitoring sistemi qurulmadı — bu bir research təcrübəsi idi, production deployment deyil. Lakin real sistemdə WER-i canlı izləmək, uğursuz tanımları qeydə almaq və istifadəçi düzəlişlərindən öyrənmək kritik əhəmiyyət daşıyır; modeli statik saxlamaq uzunmüddətli perspektivdə keyfiyyəti aşağı salır.

## Daha Çox Resurs Olsaydı — Növbəti 3 Prioritet Addım

1. **Dataset Genişləndirilməsi (ən prioritet):** Bu layihədə yalnız 200 nümunə istifadə edildi — bu həm tapşırığın şərti, həm də Colab mühitinin vaxt məhdudiyyəti ilə bağlı idi. Lakin WER-i 14% yaxşılaşdırmaq belə kiçik datasetin nəyə qədər olduğunu sübut etdi. Daha çox resurs olsaydı, ilk addım bu rəqəmi 5,000-10,000-ə çatdırmaq olardı: Azərbaycan radio/TV arxivləri, audiokitablar, ictimai çıxışlar potensial mənbədir. Fon küyü əlavəsi, sürət dəyişimi, pitch dəyişimi kimi augmentation metodlarıyla dataset süni yolla da zənginləşdirilə bilər.
2. **Dil Modeli (LM) İnteqrasiyası:** Bu layihədə LM inteqrasiyası edilmədi — Hugging Face pipeline-ı LM olmadan da işləyir və məqsəd whisper-in özünün Azərbaycanca nə qədər öyrənə biləcəyini görmək idi. Lakin nəticədə açıq göründü ki, model morfoloji xətalara (şəkilçi problemləri, söz bölgüsü) tək öz başına düzəldə bilmir. Əlavə resurs olsaydı, KenLM və ya Transformer əsaslı Azərbaycanca dil modeli beam search mərhələsinə inteqrasiya edilərdi — bu, WER-i faktiki olaraq 10-15% daha aşağı sala bilərdi.
3. **Daha Güclü Model Arxitekturası:** whisper-small seçildi, çünki Colab T4-də whisper-large-v3-ü fine-tune etmək həm yaddaş baxımından (GPU OOM riski), həm də vaxt baxımından mümkün deyildi — eyni 500 addım large modeldə 5-6 saata çıxırdı. Bu şəraitdə small əlabatən seçim idi. Daha güclü GPU əlçatımlı olsaydı, whisper-large-v3 ilə fine-tuning ikinci prioritet addım olardı; eyni 200 nümunədən belə daha yaxşı nəticə əldə etmək olardı.

**Yekun qeyd:** Azərbaycan dili üçün ASR-ın ən böyük problemi, dilin mürəkkəb morfoloji quruluşuna uyğun keyfiyyətli və etikətlənmiş səs məlumatlarının çatışmazlığıdır.